Aprendizaje de Máquina Aplicado — EAFIT

Predicción de valor mediano de vivienda en California

Entrega 1 de 3: Formulación del problema, datos, EDA y baseline

Estudiantes: Ana Sofia Rodriguez · Mariana Gutierrez · Esteban Giraldo

Dataset: California Housing (scikit-learn)

Tarea: Regresión supervisada

Fecha: 9 de abril de 2026

Medellín, Colombia · 2026

Resumen

El presente trabajo aborda la predicción del valor mediano de vivienda por distrito censal en California mediante técnicas de aprendizaje de máquina, siguiendo una primera aproximación basada en el marco CRISP-DM. El problema se formula como una tarea de regresión supervisada, en la que la variable objetivo corresponde a `MedHouseVal`, expresada en dólares estadounidenses. Para ello, se emplea el conjunto de datos California Housing, disponible en la librería *scikit-learn*, el cual contiene 20,640 registros y ocho variables predictoras de carácter socioeconómico y geográfico, sin presencia de valores nulos.

A partir del análisis exploratorio de datos (EDA), se identificaron patrones relevantes en la distribución de las variables, destacándose el ingreso mediano del hogar (`MedInc`) como el predictor con mayor correlación lineal respecto al valor de la vivienda. Asimismo, se evidenció la existencia de valores atípicos en variables como `AveRooms`, `AveBedrms` y `AveOccup`, así como un truncamiento en la variable objetivo en valores superiores a $500,000, lo que introduce un sesgo en el extremo superior de la distribución.

Como punto de referencia inicial, se implementó un modelo `DummyRegressor` que predice la media del conjunto de entrenamiento, obteniendo un error absoluto medio (MAE) de $90,607. Este resultado no pretende ser competitivo, sino establecer un baseline reproducible que permita contextualizar el desempeño de modelos más sofisticados en etapas posteriores. En conjunto, este trabajo se enfoca en comprender el problema, caracterizar los datos y sentar bases sólidas para el desarrollo de modelos en las siguientes fases del proyecto.

1 Formulación del problema

1.1 Pregunta de investigación

¿Es posible estimar el valor mediano de vivienda de un distrito censal de California a partir de características socieconómicas y geográficas del censo de 1990, con un error absoluto medio (MAE) menor al 20 % del valor mediano observado en el conjunto de prueba?

1.2 Motivación y contexto

El valor de la vivienda es una variable clave en la toma de decisiones individuales, ya que influye directamente en procesos como la compra, venta o inversión en bienes raíces. Contar con estimaciones razonables del precio de una propiedad a partir de características observables permite a los individuos tomar decisiones más informadas, incluso en contextos donde no se dispone de información completa del mercado.

En este trabajo se aborda la estimación del valor mediano de vivienda en distritos censales de California a partir de variables socioeconómicas y geográficas. Este problema refleja escenarios reales en los que es necesario inferir precios a partir de información agregada, como ingresos, densidad poblacional o ubicación.

Desde la perspectiva de aprendizaje de máquina, se trata de un problema de regresión adecuado para análisis aplicado, ya que combina relaciones no triviales entre variables con retos prácticos como outliers y truncamiento en la variable objetivo. Esto permite evaluar modelos de manera rigurosa y comprender mejor los factores que determinan el valor de la vivienda.

1.3 Variable objetivo

Variable	median_house_value
Tipo	Numérica continua (USD)
Rango observado	\$14,999 – \$500,001
Nota importante	Los valores > \$500,000 están truncados en \$500,001. Esto introduce un sesgo en el extremo superior de la distribución que debe tenerse en cuenta en la evaluación

Cuadro 1: Variable objetivo

1.4 Tipo de tarea

El problema es de **regresión supervisada**: la variable objetivo es continua y se dispone de etiquetas para todos los registros del dataset. No se trata de clasificación porque predecir una categoría de precio sería una simplificación que perdería información valiosa sobre la magnitud del error.

1.5 Métricas de evaluación

Se utilizarán tres métricas complementarias. La métrica principal es el MAE.

Métrica	**Fórmula**	**Cuándo priorizar**
MAE	$\frac{1}{n}\sum\lvert y-\hat{y}\rvert$	Variable con outliers
RMSE	$\sqrt{\frac{1}{n}\sum(y-\hat{y})^2}$	Penalizar errores grandes
R^2	$1-\frac{SS_{res}}{SS_{tot}}$	Comunicar a no técnicos

Cuadro 2: Métricas de evaluación utilizadas

Se elige MAE como métrica principal porque la variable objetivo representa outliers por el truncamiento en $500k, y MAE es más robusto a ese efecto que RMSE. R^2 se reporta como métrica secundaria para facilitar la comunicación con audiencias no técnicas.

2 Descripción del dataset

2.1 Información general

Campo	Detalle
Nombre	California Housing Dataset
Fuente	Pace, R.K. y Barry, R. (1997). Sparse Spatial Autoregressions. Statistics & Probability Letters, 33, 291-297.
Acceso	`sklearn.datasets.fetch_california_housing()`
Año	Censo de California, 1990
Registros	20,640 distritos censales
Variables	8 features + 1 target
Valores nulos	Ninguno (dataset limpio)
Licencia	Dominio público

Cuadro 3: Ficha técnica del dataset

2.2 Descripción de variables

Variable	Descripción	Tipo	Rango aprox.
MedInc	Ingreso mediano del hogar (en decenas de miles de USD)	Continua	0.5 – 15.0
HouseAge	Edad mediana de las viviendas en el bloque (años)	Continua	1 – 52
AveRooms	Promedio de habitaciones por hogar	Continua	0.8 – 141
AveBedrms	Promedio de dormitorios por hogar	Continua	0.3 – 34
Population	Población del bloque censal	Continua	3 – 35,682
AveOccup	Promedio de ocupantes por hogar	Continua	0.7 – 1,243
Latitude	Latitud del bloque censal	Continua	32.5 – 42.0
Longitude	Longitud del bloque censal	Continua	-124.4 – -143.3
median_house_value	Valor mediano de vivienda (TARGET) en USD	Continua	14,999 – 500,001

Cuadro 4: Descripción de las variables

2.3 Limitaciones y riesgos

A pesar de su utilidad para modelado, el dataset presenta varias limitaciones que deben considerarse en la interpretación de resultados.

En primer lugar, los datos provienen del censo de 1990, por lo que no reflejan las condiciones actuales del mercado inmobiliario. Esto implica que cualquier modelo construido tendrá valor analítico, pero no necesariamente predictivo en contextos reales contemporáneos.

En segundo lugar, la variable objetivo presenta un truncamiento en $500,001, lo que introduce un sesgo en el extremo superior de la distribución. Como consecuencia, el modelo no podrá aprender correctamente el comportamiento de las viviendas de mayor valor, tendiendo a subestimar estos casos.

Adicionalmente, aunque el dataset no contiene valores nulos, sí presenta outliers significativos en variables como `AveRooms`, `AveBedrms` y `AveOccup`. Estos valores extremos pueden afectar el desempeño de modelos sensibles a la escala o a la distribución de los datos.

Otro aspecto a considerar es que las variables disponibles son agregadas a nivel de distrito censal, lo que implica una pérdida de granularidad. Esto puede ocultar variaciones importantes a nivel individual y limitar la capacidad del modelo para capturar patrones más finos.

Finalmente, existe el riesgo de inferencias causales incorrectas. Las relaciones identificadas por el modelo son de naturaleza correlacional, por lo que no deben interpretarse como evidencia de causalidad entre las variables explicativas y el valor de la vivienda.

3 Análisis exploratorio de datos

3.1 Distribución de la variable objetivo

La variable objetivo `MedHouseVal` presenta una distribución asimétrica positiva con valores que oscilan entre $14,999 y $500,001, como se observa en la Figura 1.

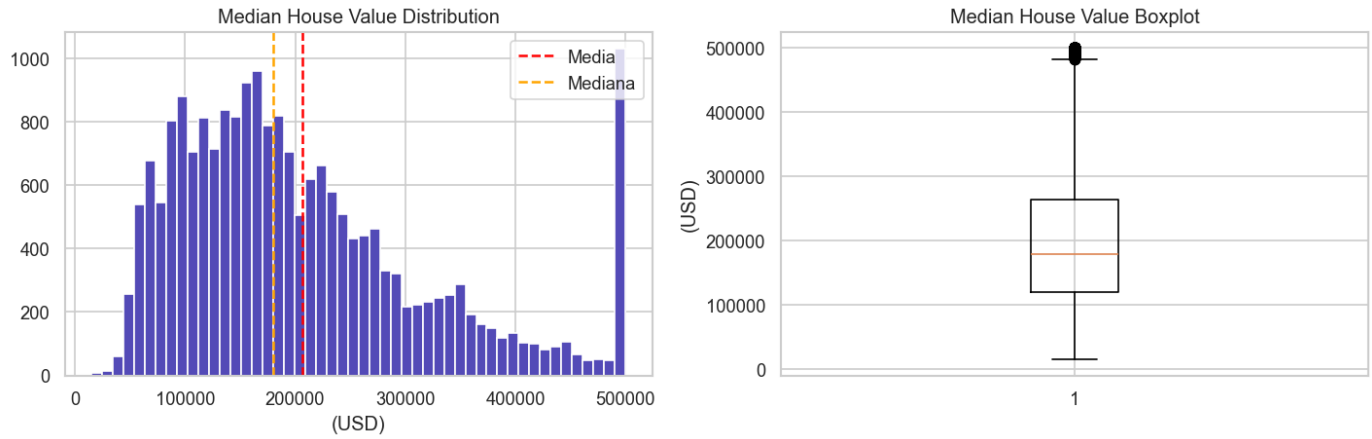

Figura 1: Distribución de `MedHouseVal`.

El histograma revela tres características relevantes para el modelado. En primer lugar, la distribución es asimétrica positiva: la media ($206,855) se ubica $27,155 por encima de la

mediana ($179,700), lo que indica que un conjunto de distritos con valores muy altos jala la media hacia arriba. Esto justifica el uso del MAE como métrica principal, ya que es más robusto ante esta asimetría que el RMSE. En segundo lugar, el boxplot confirma la presencia de valores atípicos en el extremo superior, consistentes con distritos de alto valor concentrados en zonas costeras como San Francisco y Los Ángeles, hallazgo que se corrobora en el análisis geográfico de la Sección 3.4. En tercer lugar, el pico artificial en $500,001 corresponde al truncamiento del dataset: aproximadamente el 4.8 % de los registros superaban ese umbral y fueron registrados con ese valor fijo. Esta limitación introduce un sesgo sistemático en el extremo superior que ningún modelo puede corregir sin información adicional, por lo que se espera que el error de predicción sea mayor en ese rango de valores.

3.2 Distribución de los features

La Figura 2 muestra las distribuciones de las 8 variables de entrada, las cuales pueden agruparse en tres categorías según su comportamiento distribucional.

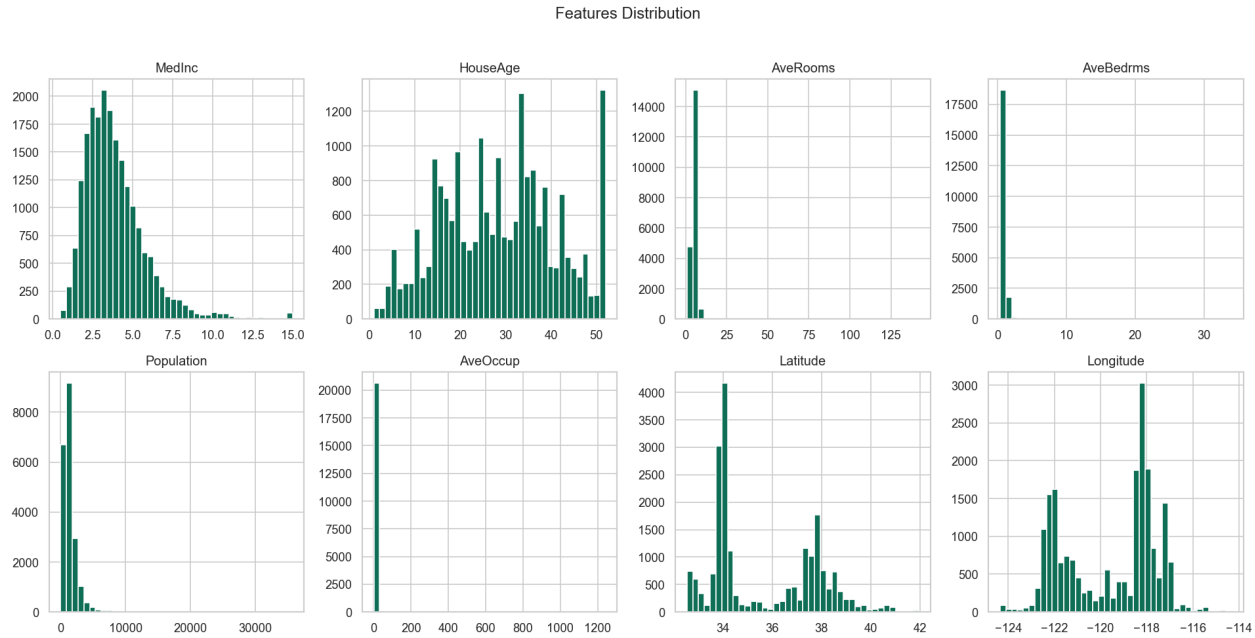

Figura 2: Distribuciones de las 8 variables de entrada.

Variables con distribución aproximadamente normal. `MedInc` es la única variable del dataset con una distribución razonablemente simétrica, con la mayoría de los valores concentrados entre $15,000 y $60,000 de ingreso mediano por hogar y una cola derecha moderada, lo que la convierte en la variable más estable para el modelado y es consistente con su alta correlación con el target ($r = 0.69$), analizada en la Sección 3.3. **Variables con sesgo positivo severo y outliers extremos.** `AveRooms`, `AveBedrms`, `Population` y `AveOccup`

presentan el mismo patrón: una alta concentración en valores bajos seguida de una cola derecha extensa; en particular, `AveRooms` alcanza valores de hasta 141.9 habitaciones por hogar y `AveOccup` hasta 1,243 ocupantes por hogar, lo que sugiere presencia de outliers asociados a registros atípicos o inconsistentes, por lo que estas variables requerirán tratamiento (winsorizing, transformación logarítmica o ambos) para evitar distorsiones en el modelado.
Variables con truncamiento o distribución bimodal. `HouseAge` presenta un pico en 52 años debido a truncamiento, mientras que `Latitude` y `Longitude` muestran distribuciones bimodales que reflejan la concentración geográfica en regiones como San Francisco (37–38°) y Los Ángeles (34°), siendo esto una característica estructural del territorio más que un problema de calidad de datos.

3.3 Correlaciones

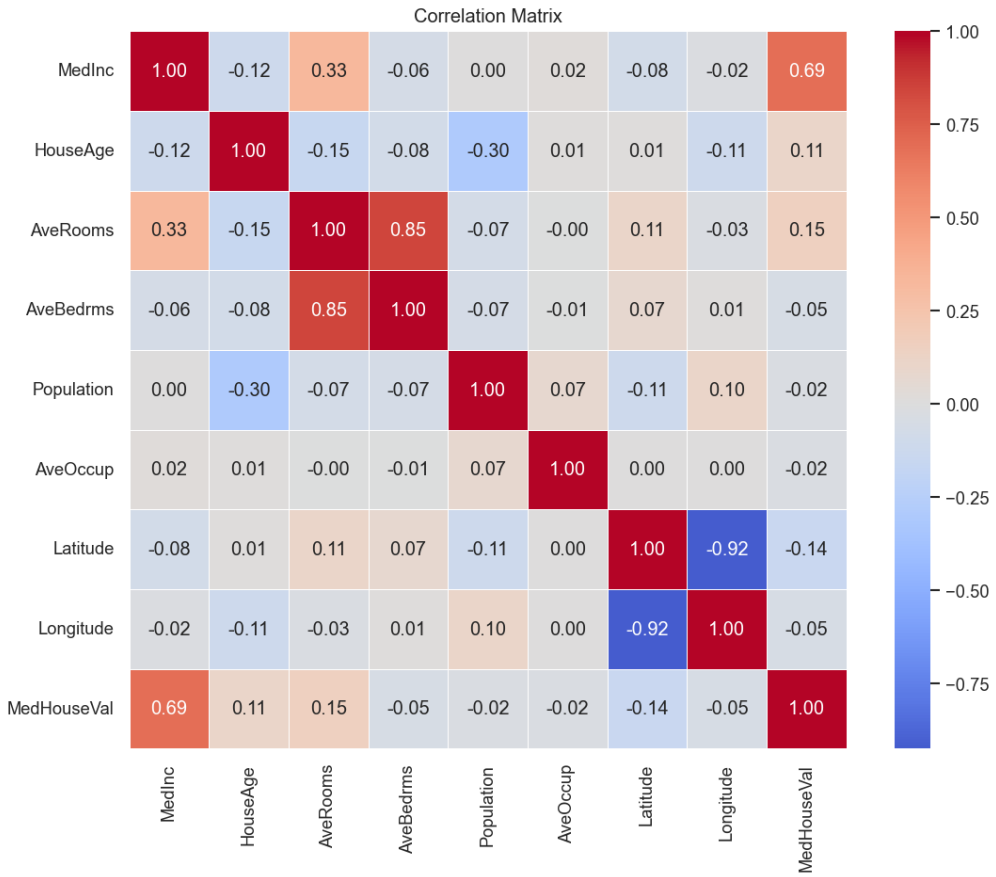

Figura 3: Matriz de correlaciones de Pearson.

De esta figura podemos encontrar tres hallazgos:

`MedInc` es el predictor con mayor correlación lineal con el target (r = 0.69), confirmando

que el ingreso mediano del distrito es la señal más fuerte para estimar el valor de una vivienda. Le siguen `AveRooms` ($r = 0.15$) y `HouseAge` ($r = 0.11$). El resto de variables muestra correlaciones lineales cercanas a cero con el target, lo que no implica ausencia de poder predictivo, sino que su relación con `MedHouseVal` puede ser no lineal y se puede capturar con otros modelos como Random Forest o XGBoost.

Se identifican 2 pares de variables con multicolinealidad alta. El primero es `AveRooms`–`AveBedrms` ($r = 0.85$): ambas miden aspectos del tamaño de la vivienda y se mueven casi en paralelo, lo que puede generar inestabilidad en los coeficientes de modelos lineales. El segundo es `Latitude`–`Longitude` ($r = -0.92$), reflejando la geometría diagonal de California. Ambos pares deberán tenerse en cuenta en la Entrega 2 al interpretar la importancia de variables: si dos features están altamente correlacionados, el modelo puede distribuir su peso predictivo entre ambos de forma arbitraria, dificultando la interpretación individual de cada uno.

`AveOccup` ($r = -0.02$) y `Population` ($r = -0.02$) presentan correlaciones prácticamente nulas con el target. Sin embargo, dado que estas variables tienen distribuciones extremadamente sesgadas con outliers severos, la correlación de Pearson no es un estimador confiable de su relación real con `MedHouseVal`. Su contribución predictiva se evaluará más rigurosamente en la Entrega 2.

3.4 Análisis geográfico

La Figura 4 muestra la distribución espacial del valor mediano de vivienda a partir de las coordenadas geográficas de cada distrito censal.

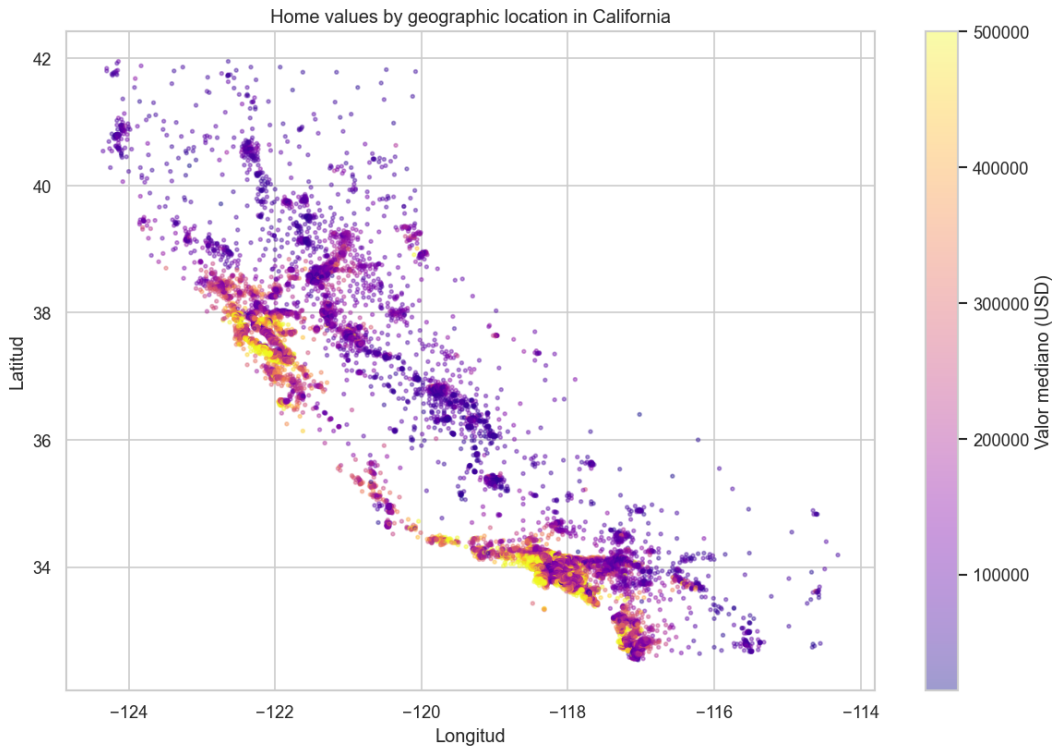

Figura 4: Valor de vivienda por ubicación geográfica.

El patrón espacial es claro y consistente con el conocimiento del mercado inmobiliario californiano. Los valores más altos (puntos amarillos y claros) se concentran en dos franjas costeras bien definidas: el área de la bahía de San Francisco y la zona de Los Angeles. En contraste, el interior del estado está dominado por puntos morados que corresponden a valores de vivienda más bajos.

De aquí, podemos sacar dos implicaciones directas para el modelado. Primero, se justifica incluir estas dos variables como features en todos los modelos, a pesar de su baja correlación lineal con el target, ya que su poder predictivo reside en la interacción entre ambas. Segundo, sugiere que modelos capaces de capturar interacciones no lineales entre variables, como Random Forest o XGBoost, tendrán una ventaja estructural sobre la regresión lineal simple para explotar este patrón geográfico.

3.5 Resumen de hallazgos

1. El dataset no presenta valores nulos, lo que permite trabajar directamente sin necesidad de imputación y reduce el riesgo de introducir sesgos artificiales en el preprocesamiento.

2. `MedInc` es el predictor con mayor relación lineal con la variable objetivo ($r = 0.69$), lo que sugiere que el ingreso mediano es el principal determinante del valor de la vivienda

dentro del conjunto de variables disponibles.

3. Las variables `AveRooms`, `AveBedrms` y `AveOccup` presentan outliers significativos, lo que puede afectar negativamente a modelos sensibles a valores extremos y requerirá tratamiento en etapas posteriores.

4. La ubicación geográfica muestra un patrón claro: las zonas cercanas a la costa presentan valores de vivienda más altos, indicando que las variables espaciales (`Latitude`, `Longitude`) contienen información predictiva relevante.

5. Se observa multicolinealidad entre algunas variables derivadas (por ejemplo, entre `AveRooms` y `AveBedrms`), lo que podría impactar la estabilidad de modelos lineales y su interpretación si no se maneja adecuadamente.

4 Separación de conjuntos

El dataset se dividió en una proporción 80/20 mediante `train_test_split` de scikit-learn, con `random_state = 42` fijo para garantizar que la partición sea idéntica en cualquier ejecución del notebook. Esto produjo 16,512 registros de entrenamiento y 4,128 de prueba, ambos con la misma distribución esperada dado el tamaño muestral.

Conjunto	**Registros**	**Uso**
Entrenamiento	16,512 (80 %)	Ajuste de modelos y validación cruzada
Prueba	4,128 (20 %)	Evaluación final únicamente

Cuadro 5: Resumen de la separación de conjuntos

Se rige una regla anti-leakage: el conjunto de prueba no es visto por ningún componente del pipeline hasta la evaluación final de cada entrega. En términos prácticos esto implica que todas las estadísticas descriptivas utilizadas para tomar decisiones de preprocesamiento — medias, medianas, percentiles, rangos — se calculan exclusivamente sobre el conjunto de entrenamiento.

Para la Entrega 2 se adoptará una estrategia de validación cruzada de 5 pliegues (*5-fold cross-validation*) sobre el conjunto de entrenamiento para la selección de hiperparámetros y la comparación entre familias de modelos. Esta estrategia divide el entrenamiento en 5 subconjuntos iguales, usando 4 para entrenar y 1 para validar en cada iteración, rotando hasta que todos los pliegues hayan servido como validación. El resultado es una estimación del desempeño más robusta que un único holdout de validación, ya que promedia el error

sobre 5 particiones distintas y reduce la varianza asociada a una división aleatoria particular. El conjunto de prueba permanecerá reservado y solo se utilizará una vez, al reportar los resultados finales.

5 Baseline reproducible

5.1 Descripción

El baseline consiste en un modelo `DummyRegressor` con estrategia `mean`, que predice siempre el valor promedio de `MedHouseVal` calculado sobre el conjunto de entrenamiento ($207,195) independientemente de los valores de entrada. Este modelo no aprende ningún patrón de los datos, ignora completamente los features, y representa el caso más simple posible de predicción. Su propósito no es ser útil en la práctica, sino establecer un piso de referencia cuantificado: cualquier modelo real que no supere estas métricas no aporta valor predictivo sobre la alternativa trivial de predecir siempre la media.

Métrica	**Valor**	**Interpretación**
MAE	$90,607	50.7 % del valor mediano
RMSE	$114,486	Penalización por errores extremos
R^2	$\approx 0{,}0$	Esperado para `DummyRegressor`

Cuadro 6: Resultados del baseline sobre el conjunto de prueba

5.2 Interpretación de la dificultad

Los resultados del baseline permiten estimar la dificultad del problema antes de construir cualquier modelo real. Un MAE de $90,607 equivalente al 50.7 % del valor mediano indica que predecir sin ningún conocimiento de los features genera un error promedio de casi la mitad del precio típico de una vivienda, lo que representa un margen de mejora amplio y alcanzable.

El RMSE de $114,486 es notablemente mayor que el MAE, lo que confirma la presencia de errores muy grandes en casos puntuales. Estos errores extremos corresponden principalmente a los distritos con valores truncados en $500,001, donde el baseline predice $207,195 incurriendo en un error mínimo de $292,806 por registro. Esta brecha entre MAE y RMSE persistirá en todos los modelos mientras el truncamiento no sea tratado explícitamente.

El R^2 de 0.0 es el resultado esperado por definición matemática para un modelo que predice siempre la media: al no capturar ninguna varianza del target, la suma de residuos cuadrados es igual a la varianza total, llevando el coeficiente exactamente a cero. Este valor no

es un fracaso del baseline sino su comportamiento correcto, y sirve como punto de referencia absoluto.

6 Conclusiones y próximos pasos

6.1 Conclusiones

Los resultados obtenidos en esta primera etapa del proyecto permiten concluir que la predicción del valor de la vivienda constituye un problema adecuado para la aplicación de técnicas de regresión supervisada, dada la naturaleza continua de la variable objetivo y la disponibilidad de datos etiquetados. El análisis exploratorio de datos facilitó la identificación de relaciones relevantes entre las variables, evidenciando que el ingreso mediano del hogar (`MedInc`) es el factor con mayor influencia en la variación del precio de la vivienda.

Asimismo, se identificaron desafíos importantes asociados a la calidad de los datos, como la presencia de valores atípicos y el truncamiento de la variable objetivo, los cuales deberán ser tratados cuidadosamente en etapas posteriores. Estos aspectos refuerzan la necesidad de aplicar técnicas de preprocesamiento y selección de modelos adecuadas para mitigar su impacto en el desempeño predictivo.

El modelo baseline implementado cumple el objetivo de establecer una referencia reproducible, evidenciando que el problema no es trivial y que existe un margen amplio de mejora mediante modelos más elaborados. En este sentido, esta primera entrega no busca optimizar el desempeño, sino construir una comprensión sólida del problema y definir un punto de partida metodológicamente correcto.

En conjunto, los hallazgos obtenidos permiten orientar el desarrollo de las siguientes etapas del proyecto, en las cuales se abordará el diseño de pipelines de modelado, la comparación de diferentes familias de modelos y la implementación de estrategias de validación más robustas.

6.2 Próximos pasos

Como continuación del proyecto, la siguiente etapa se enfocará en la construcción y comparación de modelos de regresión más elaborados, con el objetivo de mejorar el desempeño obtenido por el baseline. En particular, se evaluarán diferentes familias de modelos, incluyendo regresión lineal y sus variantes regularizadas (Ridge, Lasso), así como modelos no lineales basados en árboles de decisión y métodos de ensamble como Random Forest y Gradient Boosting, seleccionados por su capacidad para capturar relaciones no lineales presentes en los datos.

De manera complementaria, se desarrollarán pipelines de preprocesamiento que incluyan el tratamiento de valores atípicos, transformaciones de variables y análisis de multicolinealidad, con el fin de mejorar la estabilidad y capacidad predictiva de los modelos. Estas transformaciones se aplicarán exclusivamente sobre el conjunto de entrenamiento, con el objetivo de evitar fuga de información y garantizar una evaluación metodológicamente correcta.

En términos de validación, se avanzará hacia esquemas más robustos, como validación cruzada, que permitan obtener estimaciones más estables del desempeño de los modelos y realizar comparaciones justas entre diferentes alternativas. Asimismo, se analizarán múltiples métricas de evaluación, incluyendo MAE, RMSE y R^2, con el fin de comprender mejor los trade-offs entre precisión promedio y penalización de errores extremos.

Finalmente, en la etapa final del proyecto se seleccionará el modelo con mejor desempeño y se realizará un análisis más profundo de sus resultados, incluyendo interpretación de variables relevantes, análisis de errores y discusión de limitaciones. Esto permitirá no solo evaluar el modelo desde una perspectiva predictiva, sino también extraer conclusiones útiles sobre los factores que influyen en el valor de la vivienda.

Referencias

[1] Pace, R.K. y Barry, R. (1997). *Sparse Spatial Autoregressions*. Statistics & Probability Letters, 33, 291–297.

[2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[3] James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.